Informe – Desafío 1: Mesa de Pedidos

***Institución**: ICARO - UNC - FCEFyN*
***Programa:** Diplomatura Universitaria de Formación Continua en IA Engineering*
***Estudiante:** Mariana Aiello - **Docente**: Lucas Romano Miller*
***Repositorio:** github.com/Aiello-M/AI-Engineering_Desafio1_Mesa-de-Pedidos*

Introducción

Ferretería Industrial Andina recibe consultas y pedidos por WhatsApp y correo electrónico, que actualmente se procesan de forma manual. Para atenderlos, se desarrolló un grafo con LangGraph. El sistema identifica al cliente y clasifica cada mensaje como consulta, pedido o derivación. Las consultas se responden con información de los PDF de la empresa, citando documento y página. Para los pedidos, se utilizan el catálogo y los datos de crédito. Cuando se necesita autorización, el proceso se detiene hasta que intervenga Gerencia Comercial. El LLM interpreta los mensajes, mientras que Python calcula los importes y aplica las reglas comerciales.

1. Cómo correrlo

Se requiere Python 3.13 y una API key de OpenAI. Desde la carpeta del proyecto, en PowerShell:

1. `py -3.13 -m venv .venv` y `.\.venv\Scripts\Activate.ps1`
2. `python -m pip install -r requirements.txt`
3. `Copy-Item .env.example .env` y completar `OPENAI_API_KEY`
4. `python indexar.py` (crea el índice una sola vez)
5. `python correr.py MSG-009` y `python evaluar.py`

Cuando un pedido necesita aprobación, python correr.py MSG-013 guarda el estado y deja el proceso pendiente. Puede retomarse más tarde con la opción --aprobar o --rechazar, incluso después de cerrar la terminal. Los 32 tests automatizados se ejecutan sin API key mediante python -m pytest.

2. El Grafo

El grafo tiene 9 nodos y 3 routers. El diagrama completo, generado con draw_mermaid(), está incluido en el README.

El recorrido comienza con cargar_cliente y clasificar. Si el mensaje es una consulta, pasa a responder_consulta. Si es un pedido, continúa por extraer_pedido y validar_pedido, donde se determina si corresponde confirmar, rechazar, derivar o solicitar aprobación.

El nodo aprobacion_humana detiene el proceso mediante interrupt() y permite retomarlo para confirmar o rechazar el pedido. Los routers solo leen la decisión que registró el nodo anterior en el estado: ninguna bifurcación se resuelve con un if dentro de un nodo. La clasificación y la extracción utilizan Pydantic para obtener respuestas estructuradas. El estado se define mediante un TypedDict y el registro de pasos se acumula con un reducer.

3. Las decisiones y por qué

Chunks por artículo: con una división fija (chunk_size de 1.000 caracteres y overlap de 150), la regla general de devoluciones y la excepción para zapatos de seguridad quedaban en chunks distintos. Esto podía provocar una respuesta incorrecta en el MSG-003. Por eso se decidió dividir los PDF por artículo, apartado o ficha técnica. Se obtuvieron 59 chunks de entre 136 y 810 caracteres, cada uno identificado con el nombre del documento.

Búsqueda híbrida: FAISS, con text-embedding-3-small, permite recuperar información por significado, aunque se utilicen palabras diferentes. BM25 favorece las coincidencias exactas, como los códigos HE-

4330 y HE-4335. Ambos métodos se combinan mediante EnsembleRetriever, con el mismo peso, para recuperar los cuatro fragmentos más relevantes.

Reglas y cálculos: las herramientas consultar_producto y verificar_credito consultan los CSV del catálogo y de clientes. Las llama el nodo validar_pedido en todos los pedidos, no un agente, por lo que el stock y el crédito se revisan siempre. Las condiciones comerciales están definidas en un JSON y los importes se calculan con Decimal. También se utiliza Python para calcular fechas. En el MSG-005, el LLM identifica la fecha del presupuesto y Python cuenta los cinco días hábiles del artículo 2: el presupuesto emitido el 10/09 venció el 17/09.

Cuándo interviene Gerencia: se solicita autorización cuando el pedido supera el límite de crédito, existe una mora de 30 a 60 días, se pide un descuento mayor al permitido, falta stock, no se alcanza el pedido mínimo o se pide un plazo superior al autorizado. El descuento máximo es del 20 % general y del 15 % para herramientas eléctricas Dewalt, Makita y Bosch. Con más de 60 días de mora, solo se permite comprar mediante pago anticipado.

Aprobación humana: la información presentada a Gerencia incluye los datos del cliente, su situación crediticia, los productos, los importes y los motivos de la autorización. Si se aprueba el pedido, se recalculan las cantidades según el stock disponible y el resto queda pendiente. Se utiliza SqliteSaver para guardar el estado y retomar la ejecución mediante el identificador del mensaje.

Casos con respuestas incorrectas:

- **MSG-001:** indicó un descuento del 0 % para una compra de $1.200.000, cuando correspondía el 5 %, y ubicó Villa María en zona 1 en lugar de zona 2. El fragmento correcto se había recuperado, pero el modelo comparó mal el monto con los rangos de la tabla. Por el mismo motivo, los importes de los pedidos se calculan en Python. No se modificó el prompt para corregir este caso, para no ajustar el sistema al golden set.
- **MSG-006:** indicó correctamente una garantía de 12 meses, pero la mezcló con el plazo de diez días establecido para reclamar faltantes.
- **MSG-007:** aplicó a La Pampa el límite de 24 aerosoles, aunque esa restricción corresponde solamente a las zonas 4 y 5.

Los dos últimos casos contienen el dato clave esperado, por lo que cumplen la comprobación automática de ese dato, aunque las respuestas completas no sean correctas. Por este motivo, se revisaron manualmente las ocho consultas.

4. Los números

Medición	Híbrida	Solo embeddings
Ruta correcta	**20 / 20**	20 / 20
Consultas con el dato clave	**7 / 8**	7 / 8
Intención correcta	20 / 20	20 / 20
Documento recuperado y citado	8 / 8	8 / 8
Precisión / recall de los productos	1,0 / 1,0	1,0 / 1,0
Respuestas correctas revisadas a mano	5 / 8	–

Las dos búsquedas obtuvieron los mismos resultados en todas las métricas. Se mantuvo la búsqueda híbrida porque permite encontrar códigos exactos de productos.

Lo que más tiempo llevó: convertir las condiciones comerciales en reglas de Python. Fue necesario revisar cada artículo y resolver aspectos que el documento no aclaraba completamente, como la base de cálculo del descuento por volumen.

En una primera versión, un cliente suspendido podía realizar un pedido con pago al contado, aunque el artículo 7 exige pago anticipado. Se corrigió esa condición y se agregó un test. También llevó tiempo revisar manualmente las consultas, ya que siete contenían el dato clave esperado, pero solo cinco respuestas eran completamente correctas.